Factorer MPI - dokumentacja projektowa

Rafał Duraj, Piotr
 Dowgiałło, Bartosz Janusz, Maciej Kolański 2016-06-07

Spis treści

1	Temat projektu Zakres projektu 2.1 Cel			2
2				2 2
	2.2		jonalność	2
3	Narzędzia i technologie zastosowane w projekcie			3
	$3.1 \\ 3.2$		sowane technologie	3 4
4	Akt	Aktualny stan rynku		
5	Projekt techniczny			5
	5.1	Klaste	er obliczeniowy	5
	5.2	Strona	a internetowa	5
6	Dokumentacja powykonawcza (instalacyjna)			11
	6.1	Wyma	agania systemowe	11
	6.2	Konfig	guracja systemu	11
		6.2.1	Edycja pliku hosts	12
		6.2.2	Tworzenie nowego użytkownika	12
		6.2.3	Utworzenie folderu współdzielonego i udostępnienie go w	
			sieci	12
		6.2.4	Tworzenie bezhasłowego połączenia SSH	13
		6.2.5	Uruchomienie pliku wykonywalnego	13
7	Istotne elementy kodu z komentarzem			14
8	Przykładowe wyniki badań efektywności programu równeległe-			
	\mathbf{go}			14
	8.1	Testy	wydajności dla algorytmu Bruteforce	14
	8.2	Testy	wydajności dla algorytmu CFRAC	16
9	$\mathbf{W}\mathbf{n}$	Wnioski 18		

1 Temat projektu

W dzisiejszych czasach, gdy właściwie wszystko co robimy w jakiś sposób połączone jest z Internetem bezpieczeństwo jest bardzo ważnym tematem.

Faktoryzacja jest to proces podczas którego dla zadanego obiektu odnajduje się inne obiekty, które spełniają to, że ich iloczyn równy jest oryginalnemu obiektowi, w związku z czym te znalezione czynniki są w pewnym sensie od niego prostsze.

Podstawowy algorytm faktoryzacji bazuje na próbowaniu podziału liczby do faktoryzacji n
 przez wszystkie liczby pierwsze od 2 do \sqrt{n} . Tego typu algorytm bardzo dobrze radzi sobie z początkiem faktoryzacji liczby, bo dowolna liczba ma czynnik zarówno małe jak i duże. Jak wiadomo połowa wszystkich liczb
dzieli się przez dwa, jedna trzecia licz przez trzy i tak dalej, a więc z dużym prawdopodobieństwem można pozbyć się w prosty sposób niskich czynników.

RSA jest to jeden z pierwszych i też obecnie najpopularniejszych asymetrycznych algorytmów kryptograficznych gdzie klucz jest publiczny. Bezpieczeństwo szyfrowania przy pomocy tego algorytmu jest związane z trudnością faktoryzacji dużych liczb.

2 Zakres projektu

2.1 Cel

Celem projektu jest umożliwienie zlecenia zadania faktoryzacji dużej liczby (większych od $2^{64}-1$). Jednym z głównych założeń jest udostępnienie prostego w obsłudze interfejsu użytkownika i zmaksymalizowanie elastyczności – system powinień być zdolny do współpracy z zadanymi komputerami, a instalacja wymaganego oprogramowania musi być prosta.

2.2 Funkcjonalność

Podstawowa

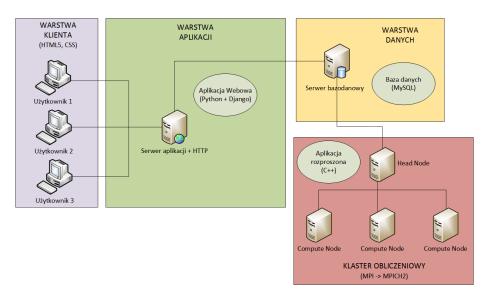
- 1. Udostępnienie mechanizmów rejestracji i logowania (konta użytkowników)
- 2. Zarządzanie zadaniami z poziomu interfejsu webowego
 - (a) zlecanie zadań
 - (b) przegląd historii
- 3. Możliwość rozbudowy klastra bez ingerencji w kod
- 4. Faktoryzacja metodą "brutalnej siły"
- 5. Faktoryzacja metodą CFRAC
- 6. Zachowywanie wyników pomyślanie wykonanych faktoryzacji

Rozszerzona

- 1. Łamanie szyfru RSA
- 2. Faktoryzacja metoda sita kwadratowego
- 3. Forma graficznej prezentacji wyników pomiarów

3 Narzędzia i technologie zastosowane w projekcie

3.1 Zastosowane technologie



Rysunek 1: Schemat blokowy systemu

Strona klienta - HTML5, CSS Interfejs z którego bedzie korzystal klient projektowanego systemu został napisany w jezyku skryptowym HTML5 z użyciem stylów CSS. HTML5 jest obecnie standardem przy tworzeniu stron internetowych i w wiekszosci wyparl HTML4, w którego specyfikacji bylo duzo niescislosci. Uzycie CSS z kolei pozwoli ujednolicic prezentacje zawartosci w różnych przegladarkach, oraz uprosci organizacje samego kodu.

Aplikacja Webowa - Python 3.4 + Django 1.8.7[1] Python jest jezykiem wysokiego poziomu ogólnego przeznaczenia, z kolei Django to framework webowy dla tego jezyka. Wybralismy ten zestaw z powodu wielu ulatwień przy

tworzeniu aplikacji webowych, które sa przezeń oferowane, np. dynamiczny interfejs bazy danych, automatyczny interfejst administracyjny. Dodatkowo czesc naszej grupy jest zaznajomiona z tymi technologiami, wiec nie ma potrzeby poznawania ich od zera. Istotne sa tutaj wersje srodowisk - najnowsze dystrybucje nie obsługuja MySQL, w zwiazku z tym wybralismy poprzednie.

Baza danych - MySQL SZBD rozwijany przez firme Oracle. Charakteryzuje sie wszystkimi najwazniejszymi funkcjonalnosciami bazy danych oraz prostota tworzenia takiej bazy. Rozważalismy zastosowanie systemu Oracle Database, jednakże jest on zbyt rozbudowany jak na nasze potrzeby, a co za tym idzie trudny w obsudze. Mamy również doswiadczenie w integracji bazy MySQL z aplikacjami napisanymi w Pythonie (Django).

Klaster obliczeniowy - standard MPI[2] MPICH2 to darmowa implementacja standardu MPI dla systemów Linux. Umożliwa proste tworzenie klastrów obliczeniowych, rozdzielania zadań miedzy poszczególne wezly i zbierania wyników. Oferuje interfejs dla jezyka C++. Jest wykorzystywany w wiekszosci topowych urzadzen wieloprocesorowych i ta popularnosc znaczaco wpłynelo na jego wybór.

Aplikacaja rozproszona - C++11 Wybór padl na ten jezyk ze wzgledu na jego znajomosc przez czlonków grupy oraz interfejs udostępniany przez srodowisko MPICH2.

3.2 Narzedzia wykorzystane w projekcie

- $\bullet\,$ Aplikacja webowa PyCharm5.0.4 IDE do Pythona, obsuguje Django
- Aplikacja rozproszona CodeLite 9.1 IDE do C++, wersja na system Linux
- Baza danych developer do MySQL
- Organizacja pracy Trello (https://trello.com/)
- Hosting plików GitHub (https://github.com/)

4 Aktualny stan rynku

GGNFS (GPL'd implementation of General Number Field Sieve) Aktywny rozwój. faktoryzacja liczb do 180 znaków, srednio do 140. Kilka wiekszych liczb tez. W wiekszosci przypadkow program GGNFS jest stabilny dla liczb skladajacych sie do 150-160 znakow. Posiada bugi. Nie jest czarna skrzynka, trzeba miec odpowiednia wiedze zeby go uzywać.

Cunningham Project Projekt faktoryzujący liczby b^n+-1 dla b=2,3,5,6,7,10,11,12 i duze n.[3]

RSA Factoring Challenge Zawody zorganizowane przez RSA Security. Otwarte zawody dla wszystkich mające na celu zwiększyć zainteresowanie faktoryzacją liczb. Opublikowana została lista pseudopierwszych liczb (rozkładających się na dokładnie dwa czynniki), nazwanych liczbami RSA.Za rozłożenie niektórych z nich wyznaczono pieniężną nagrodę. Najmniejsza z nich, 100-cyfrowa liczba RSA-100 została rozłożona w ciągu kilku dni, ale większość do dziś pozostaje niezłamana.Zawody miały na celu śledzenie rozwoju możliwości komputerów w faktoryzacji. Jest to niezwykle istotne przy wyborze długości klucza w szyfrowaniu asymetrycznym metodą RSA. Postęp w łamaniu kolejnych liczb powinien zdradzać jakie długości klucza można jeszcze uznawać za bezpieczne.[4]

5 Projekt techniczny

5.1 Klaster obliczeniowy

Komunikacja

Algorytm Brute Force

Algorytm CFRAC

5.2 Strona internetowa

Dostępna w sieci Internet strona WWW finalnie umożliwia rejestrację i logowanie użytkowników oraz zlecanie zadań, czyli liczb do faktoryzacji. Do tego użytkownik ma wgląd w historię zleconych przez niego zadań wraz z ich rozwiązaniami. Poza funkcjonalnościami dla zwykłego użytkownika strona umożliwia także działania administracyjne poprzez panel administracyjny. Do zadań tych należą takie rzeczy jak usuwanie zleconych zadań, nadawanie im priorytetu czy też zarządzanie użytkownikami. Strona współpracuje z bazą danych MySQL. Jest ona dostępna pod adresem http://156.17.235.48/.



Rysunek 2: Strona główna.

1111

Brute Force

May 23, 2016

Stronę wykonano przy użyciu technologii Python Django[1] i edytora tekstowego Sublime[5] wraz z dodatkiem Anaconda Python IDE[6]. Do komunikacji z bazą danych wykorzystano standardową bibliotekę do połączenia z MySQL dostępną w Django. Baza danych została stworzona przy pomocy ORM[7] także standardowego dla Django. Przykładowy kod dla encji Task poniżej.

```
class Task(models.Model):
   CANCELLED_STATUS = -1
   UNDONE_STATUS = 0
   WORKING_STATUS = 1
   DONE\_STATUS = 2
   STATUS\_CHOICES = (
       (CANCELLED_STATUS, "Cancelled"),
       (UNDONE_STATUS, "Undone"),
       (WORKING_STATUS, "Working"),
       (DONE_STATUS, "Done")
   )
   number_to_factor = models.CharField(max_length=200)
   job_date = models.DateField(default=timezone.now)
   state = models.IntegerField(choices=STATUS_CHOICES,
        default=UNDONE_STATUS)
   priority = models.IntegerField(default=0)
   result = models.CharField(max_length=200)
   user = models.ForeignKey(User, on_delete=models.CASCADE)
```

```
algorithm = models.ForeignKey(Algorithm, on_delete=models.CASCADE)

def __str__(self):
    return str(self.number_to_factor)
```

Kolejne kolumny danej tabeli w bazie danych są tworzone poprzez definiowanie pól klas dziedziczących po models. Model [8], tak jak powyżej na przykład kolumna result jest polem tekstowym o długości maksymalnej 200 znaków.

W celu utworzenia nowej podstrony definiuje się klasy dziedziczące po klasie View z Django. Poniżej znajduje się kod dla widoku podstrony z zadaniami użytkownika.

```
class UserView(LoggedInMixin, View):
    template_name = 'FactorerMain/userview.html'

def get(self, request, *args, **kwargs):
    tasks = Task.objects.filter(user=request.user.id)[::-1]

    context = {'tasks': tasks}

    return render(request, self.template_name, context)
```

W tym przypadku UserView dziedziczy również po klasie LoggedInMixin odpowiadającej za autoryzację, dzięki czemu do takiej podstrony ma dostęp tylko użytkownik zalogowany. W zmiennej template_name wskazano na szablon strony opisany w języku HTML. Następnie w metodzie get pobierane są wyniki z bazy danych przy pomocy metody Task.objects.filter(user=request.user.id)[::-1]. Zwróci to z encji Task wyniki należące do aktualnego użytkownika posortowane w od najnowszych do najstarszych. Na końcu zwracany jest szablon oraz kontekst, w tym przypadku zadania użytkownika, poprzez metodę render.

Można tak pobrane dane z bazy użyć w HTML i wyświetlić je na stronie. Kod wygląda następująco:

```
{% endfor %}
{% else %}
  No tasks to show.
{% endif %}
```

Pierw sprawdzane jest czy w kontekście została przekazana zmienna tasks. Następnie przy pomocy pętli for przechodzi się przez kolejne elementy tabeli i drukuje jej elementy przy pomocy składni [tabela].[element]. Przykład uzyskanych z bazy danych wyników na stronie pokazano na rysunku poniżej.

Moje zadania: Liczba 126 przy użyciu Brute Force dnia May 24, 2016 jest w stanie 2 Liczba 21212121 przy użyciu Brute Force dnia May 23, 2016 jest w stanie 2 3*7*73*101*137 Liczba 21212121 przy użyciu Brute Force dnia May 23, 2016 jest w stanie 2 Liczba 1000000000 przy użyciu Brute Force dnia May 23, 2016 jest w stanie 2 Liczba 3727481741 przy użyciu CFRAC dnia May 23, 2016 jest w stanie 2 Liczba 3727481741 przy użyciu Brute Force dnia May 23, 2016 jest w stanie 2 Liczba 1111 przy użyciu Brute Force dnia May 23, 2016 jest w stanie 2

Rysunek 3: Podstrona z zadaniami użytkownika.

W Django zazwyczaj definiuje się jeden bazowy szablon w postaci pliku HTML, a następnie na podstronach zastępuje się tylko wyróżnione bloki strony w sposób wyspecyfikowany dla danej podstrony. Uzyskuje się to przez rozszerzanie szablonów. Dla przykładu w główny pliku HTML znajduje się następujący fragment:

W tym kodzie zdefiniowano blok gallery, można go zastąpić przy pomocy poniższego fragmentu na innej stronie.

Poza blokiem gallery reszta strony będzie taka jak zdefiniowano w pliku base.html. Strona projektu składa się z jednego bazowego szablonu i rozszerzających go kilku podstron.

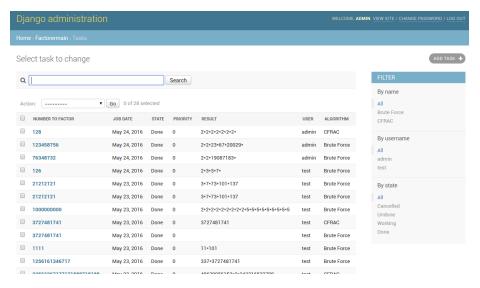
W celu połączenia wszystkiego należy zdefiniować jeszcze w pliku urls.py odwzorowania adresów url dla odpowiednich stron, dzięki czemu Django uruchamia odpowiednie klasy widoków dla zadanego adresu.

```
urlpatterns = [
   url(r'^$', views.IndexView.as_view(), name='index'),
   url(r'^userview/?$', views.UserView.as_view(), name='userview'),
   url(r'^about/?$', views.AboutView.as_view(), name='about'),
   url(r'^creators/?$', views.CreatorsView.as_view(), name='creators'),
   url(r'^bruteforce/?$', views.BruteforceView.as_view(),
        name='bruteforce'),
   url(r'^cfrac/?$', views.CFRACView.as_view(), name='cfrac'),
   url(r'^login/?$', 'django.contrib.auth.views.login'),
   url(r'^logout/?$', 'django.contrib.auth.views.logout'),
   url(r'^register/?$', views.register, name='register'),
   url(r'^success_register/?$', views.SuccessRegisterView.as_view(),
        name='success_register'),
   url(r'^admin/?', include(admin.site.urls)),
]
```

Przy tak zdefiniowanych adresach odnosi się do nich w HTML poprzez następującą linię kodu:

```
<a href="{% url 'index' %}">Strona glowna</a>}
```

Do zadań administracyjnych został wykorzystany standardowy panel Django administration skonfigurowany dla potrzeb projektu.



Rysunek 4: Panel administracyjny Django.

Panel modyfikuje się poprzez edycję pliku admin.py.

Klasa musi dziedziczyć po klasie admin.ModelAdmin, następnie można zdefiniować sposób wyświetlania danych, pola, po których ma być realizowane wyszukiwanie, czy też listę filtrów. Na końcu trzeba zarejestrować taką klasę dla danej encji.

6 Dokumentacja powykonawcza (instalacyjna)

6.1 Wymagania systemowe

System posiada następujące wymagania programowe:

- system operacyjny Ubuntu 14.04 LTS
- zainstalowana biblioteka MPICH2 w wersji 3.0.4
- klient SSH, np. openssh (1:6.6p1-2ubuntu2.7)
- serwer systemu wymiany plików NFS, np. nfs-kernel-server (1:1.2.8-6ubuntu1.2)
 na głównej maszynie klastra (master)
- klient systemu wymiany plików NFS, np. nfs-common (1:1.2.8-6ubuntu1.2)
 na pozostałych maszynach klastra (slaves)

Minimalne wymagania sprzętowe nie zostały sprecyzowane, system powinien się uruchomić na dowolnej konfiguracji z zainstalowanym powyższym oprogramowaniem. Niezbędne jest, aby wszystkie maszyny tworzące klaster były umieszczone w jednej sieci LAN pracującej w technologii FastEthernet lub wyższej. Dodatkowo węzeł główny musi posiadać połączenie z Internetem w celu komunikacji z bazą danych.

6.2 Konfiguracja systemu

Aby uruchomić system na docelowej grupie maszyn należy wykonać następujące kroki:

- zmapować adresy ip maszyn w pliku systemowym /etc/hosts
- utworzyć na każdej maszynie nowego użytkownika mpiuser
- utworzyć folder współdzielony w sieci za pomocą systemu NFS
- zapewnić bezhasłowe połączenie SSH pomiędzy węzłem głównym, a każdym węzłem obliczeniowym
- skopiować plik wykonywalny programu do folderu współdzielonego
- uruchomić plik za pomocą komendy mpirun

6.2.1 Edycja pliku hosts

Plik znajduje się w katalogu /etc. Należy edytować go w dowolnym edytorze tekstu i przypisać lokalne adresy ip do nazw hostów. Przykładowy plik:

```
127.0.0.1 localhost
#127.0.1.1 linux0

156.17.41.15 master
156.17.41.60 slave1
156.17.41.61 slave2
156.17.41.62 slave3

# The following lines are desirable for IPv6 capable hosts
::1 ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
```

6.2.2 Tworzenie nowego użytkownika

Aby utworzyć nowego użytkownika należy wykonać następującą komendę z uprawnieniami administratora:

```
$ sudo adduser mpiuser
```

Krok należy powtórzyć na każdym węźle.

6.2.3 Utworzenie folderu współdzielonego i udostępnienie go w sieci

Po zalogowaniu na konto mpiuser należy dokonać następujących kroków:

Na głównym węźle:

Utworzenie folderu cloud:

\$ mkdir cloud

Edycja pliku /etc/exports i umieszczenie w nim wpisu:

/home/mpiuser/cloud *(rw,sync,no_root_squash,no_subtree_check)

Wyeksportowanie zmian:

\$ exportfs -a

Na węzłach obliczeniowych: Utworzenie folderu cloud:

\$ mkdir cloud

Zamontowanie folderu współdzielonego do lokalnego systemu plików:

\$ sudo mount -t nfs master:/home/mpiuser/cloud ~/cloud

Sprawdzenie, czy folder został poprawnie zamontowany:

```
$ df -h
Filesystem Size Used Avail Use% Mounted on
master:/home/mpiuser/cloud 49G 15G 32G 32% /home/mpiuser/cloud
```

6.2.4 Tworzenie bezhasłowego połączenia SSH

Poniższe kroki należy wykonać na każdym węźle. Generacja pary kluczy - publicznego i prywatnego:

```
$ ssh-keygen -t dsa
```

Przesłanie klucza publicznego z węzła głównego na obliczeniowe i na odwrót: Wyłączenie konieczności podawania hasła przy logowaniu SSH:

```
$ eval 'ssh-agent'
$ ssh-add ~/.ssh/id_dsa
```

Należy przetestować połączenie pomiędzy węzłem głównym i każdym z obliczeniowych za pomocą próby zalogowania:

```
$ ssh master (slave[i])
```

6.2.5 Uruchomienie pliku wykonywalnego

Uruchomienie pliku wykonywalnego Factorer dokonuje się za pomocą komendy mpirun z określonymi parametrami. Przykładowe wywołanie:

```
$ mpirun -np 4 -hosts master,slave1 ./Factorer
```

Komenda przyjmuje następujące parametry:

• -np liczba - zbiorcza liczba wątków wykonywanych na klastrze. Przykład: System składa się z 3 jednakowych maszyn obliczeniowych i węzła głównego. Każda stacja posiada 2 rdzenie procesora. W celu równomiernego zrównoważenia obciążenia procesór wartość parametru powinna wynosić 3*2+2=8 wątków.

 -hosts hostname1,hostname2 ... - nazwy węzłów na których ma zostać uruchomiony program oddzielone przecinkami (bez spacji). Lista musi zawierać węzeł główny (master) oraz może zawierać dowolną liczbę węzłów obliczeniowych (slave).

7 Istotne elementy kodu z komentarzem

8 Przykładowe wyniki badań efektywności programu równeległego

Konfiguracja sprzętowa maszyn na których przeprowadzone zostały testy:

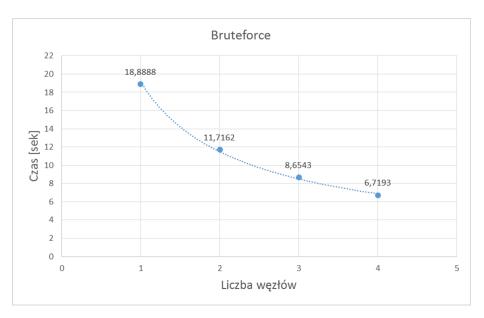
- Procesor: Interl Core i7-2600K 3.40 GHz (wykorzystywane 2 rdzenie)
- Pamięć RAM: 4096 MB
- łącze sieciowe FastEthernet 100 Mbit/s
- maszyny witualne uruchamiane w środowisku Virtualbox 5.0.20

Metodologia pomiarów:

- faktoryzowana liczba 1234567891011121314
- ilość powtórzeń pomiarów 20, wyniki uśredniono
- ullet ilość rdzeni na węzeł 2
- ilości węzłów obliczeniowych 1, 2, 3, 4

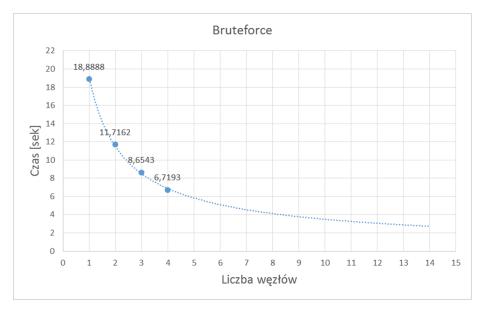
8.1 Testy wydajności dla algorytmu Bruteforce

Wyniki w formie wykresu dla algorytmu Bruteforce:



Rysunek 5: Bruteforce

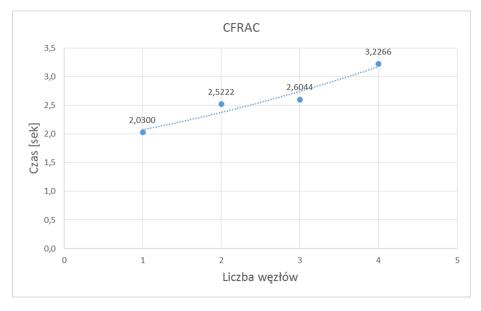
Algorytm faktoryzacji bruteforce posiada niekorzystną złożoność obliczeniową, przez co czas jego wykonania jest długi. Na wykresie widać, że dołączanie kolejnych maszyn powoduje skrócenie czasu obliczeń. Zależność czasu od ilości węzłów nie jest jednak liniowa. Wykorzystując narzędzia arkusza kalkulacyjnego można zasymulować prognozowaną linię trendu dla większej ilości maszyn. Widzimy zatem, że wzrost wydajności następuje tylko do pewnej ilości dołączanych węzłów obliczeniowych. Powyżej pewnej wartości zwiększanie ilości węzłów nie będzie powodowało przyspieszenia obliczeń.



Rysunek 6: Bruteforce - prognozowane wyniki dla 14 maszyn

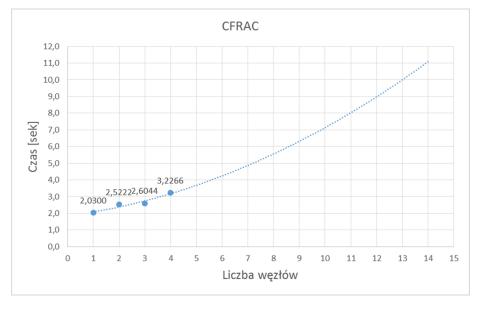
8.2 Testy wydajności dla algorytmu CFRAC

Wyniki w formie wykresu dla algorytmu CFRAC:



Rysunek 7: CFRAC

Algorytm CFRAC implementuje o wiele wydajniejszą metodę factoryzacji. Wyniki uzyskane na pojedynczym węźle obliczeniowym są około 9 razy mniejsze od wyników bruteforce dla tej samej liczby. Widać tutaj również ciekawe zjawisko. Przy dodawaniu kolejnych węzłów obliczeniowych czas wykonania zadania nie maleje, a wręcz nieznacznie wzrasta. Wydłużenie czasu jest wynikiem konieczności zużycia zasobów na rozdzielenie oraz rozesłanie podzadań do węzłów obliczeniowych, a następnie pobranie wyników cząstkowych i skompletowanie ostatecznego. Czas jest również uzależniony od prędkości przesyłu danych pomiędzy węzłami. W testach wykorzystywane było łącze FastEthernet o maksymalnej przepustowości 100 Mbit/s. Możliwe, że przy większej przepustowości dołączanie kolejnych węzłów nie powodowałoby takiego opóźnienia. W tym wypadku również można zasymulować prognozę dla większej ilości maszyn, jednakże należy ją traktować z większym dystansem niż tą dla bruteforce. Wyniki mają większe wahania, przez co trudniej było dobrać odpowiednią funkcję trendu.



Rysunek 8: CFRAC - prognozowane wyniki dla 14 maszyn

9 Wnioski

Literatura

- [1] Dokumentacja Django. https://docs.djangoproject.com/en/1.8/, 2016
- [2] Dokumentacja MPICH2. http://www.mpich.org/documentation/guides/, 2016.
- [3] Cunningham Project. http://homes.cerias.purdue.edu/~ssw/cun/
- $[4] \begin{tabular}{ll} RSA & Factoring & Challenge. \\ & {\tt Factoring_Challenge} \\ \end{tabular} \begin{tabular}{ll} {\tt http://pl.wikipedia.org/wiki/RSA_} \\ \end{tabular}$
- [5] Sublime Text Editor. https://www.sublimetext.com/
- [6] . Anaconda Python IDE http://damnwidget.github.io/anaconda/
- [7] ORM object-relational mapping. https://pl.wikipedia.org/wiki/Mapowanie_obiektowo-relacyjne
- [8] Django Models documentation. https://docs.djangoproject.com/en/1. 9/topics/db/models/